

Ders: Veri Analizi

Konu: Kalp Hastalığı Risk Tahmini (Heart Disease Prediction)

Öğrenci Adı Soyadı: Hüseyin Emre Şeker / Goncagül Uysal

1. GİRİŞ


Bu projenin amacı, bireylerin yaş, cinsiyet, kan basıncı, kolesterol ve göğüs ağrısı gibi klinik verilerini analiz ederek kalp hastalığı taşıyıp taşımadıklarını makine öğrenmesi yöntemleriyle tahmin etmektir. Kalp hastalıklarının erken teşhisi hayati önem taşıdığından, bu çalışma bir "Sınıflandırma" (Classification) problemi olarak ele alınmıştır. Veri seti olarak Kaggle platformundan temin edilen ve literatürde yaygın olarak kullanılan "Heart Disease UCI" veri seti seçilmiştir.

2. VERİ ANALİZİ (EDA)

Veri seti incelendiğinde, verinin 14 farklı öznelikten (feature) oluştuğu görülmüştür. Hedef değişkenimiz olan "Heart Disease", hastaların durumunu "Presence" (Var) ve "Absence" (Yok) olarak belirtmektedir.

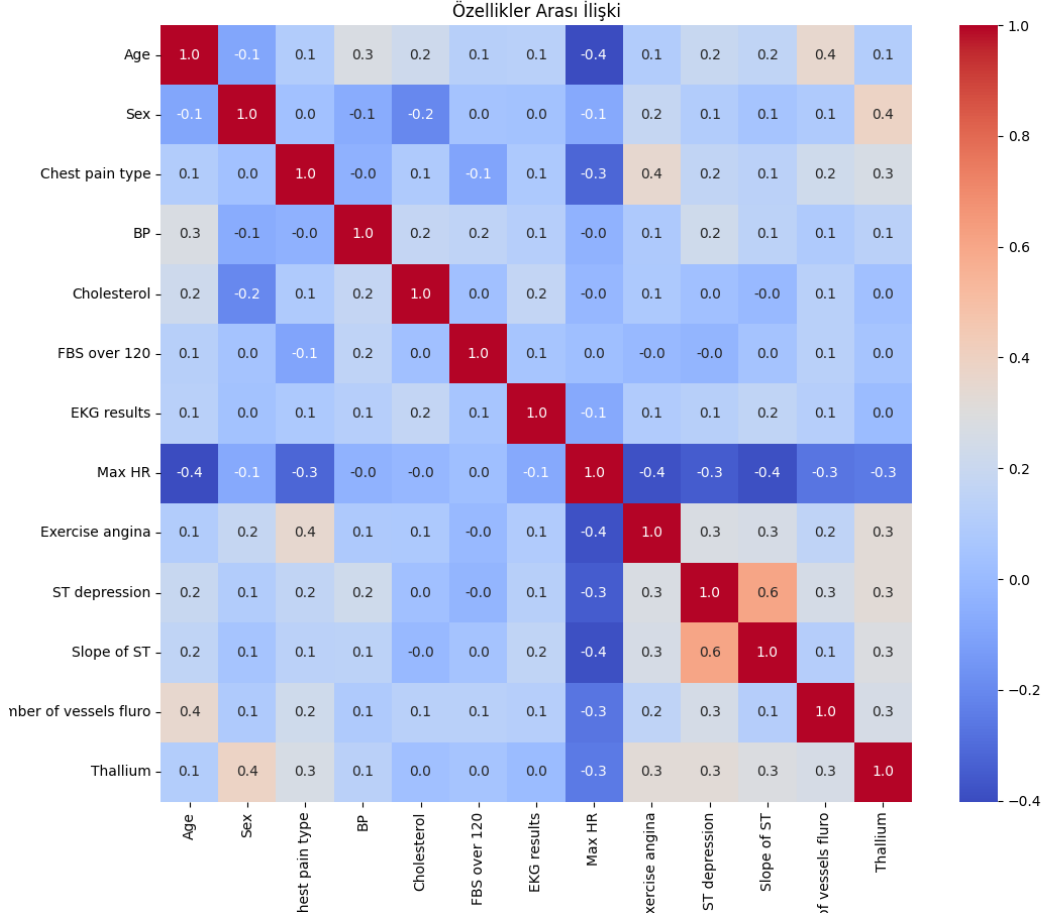
Yapılan görselleştirmeler sonucunda elde edilen temel içgörüler şunlardır:

- **Veri Dağılımı:** Veri setindeki hasta ve sağlıklı birey dağılımı incelenmiştir.



Şekil 1: Hasta ve Sağlıklı Birey Dağılımı

İlişki Analizi: Değişkenler arasındaki korelasyon matrisi incelendiğinde, özellikle göğüs ağrısı türü, maksimum kalp atış hızı ve ST depresyonu gibi değişkenlerin hastalıkla daha güçlü bir ilişkisi olduğu görülmüştür.



Şekil 2: Özellikler Arası Korelasyon Matrisi

3. YÖNTEM

Veri setindeki kategorik ifadeler (Presence/Absence) sayısal değerlere (1/0) dönüştürülmüş ve modelin performansını artırmak amacıyla tüm veriler StandardScaler kullanılarak standartlaştırılmıştır. Problemi çözmek için iki farklı algoritma seçilmiştir:

□ **Lojistik Regresyon:** Sınıflandırma problemlerinde temel referans model olduğu ve doğrusal ilişkileri iyi açıkladığı için seçilmiştir.

□ **Random Forest (Rastgele Orman):** Karar ağaçlarının topluluğundan oluşan, genellikle yüksek doğruluk veren daha karmaşık bir yapı olduğu için karşılaştırma amacıyla kullanılmıştır.

4. SONUÇLAR VE DEĞERLENDİRME

Modellerin test verisi üzerindeki başarı oranları (Accuracy) aşağıda karşılaştırılmıştır:

- **Lojistik Regresyon Başarısı:** %90.74
- **Random Forest Başarısı:** %75.93

Bulguların Yorumlanması: Beklenenin aksine, daha basit bir yapıya sahip olan **Lojistik Regresyon** algoritması, bu veri setinde Random Forest algoritmasına göre belirgin bir farkla daha başarılı olmuştur. Bu durum, veri setindeki özelliklerin hastalıkla doğrusal (linear) bir ilişki içinde olduğunu ve veri seti boyutunun Random Forest gibi karmaşık bir modeli tam kapasiteyle eğitmek için yeterince büyük olmayabileceğini göstermektedir. Lojistik Regresyon, aşırı öğrenmeye (overfitting) kaçmadan daha kararlı bir genelleme yapmıştır.

Hata Analizi: Random Forest modelinin Hata Matrisi (Confusion Matrix) incelendiğinde; modelin sağlıklı bireyleri tespitinde başarılı olduğu, ancak hasta olan bireyleri tespit etmede (Recall) zorlandığı ve bazı hastaları "sağlıklı" olarak sınıflandırdığı görülmüştür.

5. PROJE KODLARI (GitHub)

Projenin tüm kaynak kodlarına ve detaylı incelemesine aşağıdaki GitHub linkinden ulaşılabilir:

<https://github.com/SUGAR588/Kalp-Hastal-Analizi>

